

1. 프로젝트 주제 및 문제 해결의 필요성

(Project topic and the necessity of solving the problem)

프로젝트 주제: 급성 심근경색 예측

급성 심근경색(Acute Myocardial Infarction, AMI)은 심혈관계 질환 중 생명을 위협하는 주요 질병으로, 이를 조기에 예측하면 환자의 생존율을 크게 향상시킬 수 있습니다.

문제 해결의 필요성: Kamir 전자의무기록 데이터 활용

본 연구는 한국 급성 심근경색 등록사업(KAMIR) 데이터에서 수집된 수치 데이터를 활용하여 BERT를 사용한 AMI 예측 모델을 개발하였습니다.

KAMIR 데이터는 53개의 의료 센터에서 수집된 고품질의 전자의무기록(EHR) 데이터로, AMI 예측에 필요한 다양한 환자 상태와 임상 정보를 포함하고 있습니다.

본연구에서는 KAMIR 데이터를 활용하여 Train, Validation, Test 데이터셋으로 분리한 후 모델 학습 및 평가를 수행하였습니다.

데이터셋의 크기와 클래스 분포는 다음과 같습니다.

데이터셋	크기	0(생존)	1(사망)	1 비율
Train Dataset	12,503	12,095	408	3.27%
Validation Dataset	1,563	1,512	51	3.26%
Test Dataset	1,563	1,512	51	3.26%

BERT의 한계:

BERT는 자연어 처리(NLP) 작업을 위해 설계된 모델로, 원래 자연어 문장을 처리하는 데 특화되어 있습니다. 따라서, 숫자로 이루어진 Tabular 데이터를 처리하려면 이를 자연어 문장으로 변환해야 했습니다.

그러나, BERT Tokenizer는 자연어 문장 속 실수(float) 데이터를 정확히 인식하지 못해 모델 학습 과정에서 성능 저하가 발생하는 문제가 있었습니다.

해결 방안:

이러한 문제를 해결하기 위해 데이터를 자연어 문장으로 변환하는 과정을 생략하고 CSV 데이터의 수치 값을 그대로 입력하는 방식을 채택했습니다.

이로 인해 데이터 변환으로 인한 정보 손실을 방지하고, 모델이 데이터 간의 상호작용을 직접 학습할 수 있도록 설계하였습니다.

임베딩 설계:

Tabular 데이터의 각 컬럼을 독립적으로 처리하기 위해, 각 컬럼별로 Linear Layer를 생성하여 수치 데이터를 고유한 임베딩 벡터로 변환하였습니다.

이를 통해 컬럼 간의 고유한 의미를 유지하면서도 수치 데이터 간의 상호작용을 효과적으로 학습하였습니다.

Transformer 활용: 수치 데이터를 BERT의 Transformer 구조에 입력함으로써 데이터 간의 상호작용을 효과적으로 학습하였습니다.

이를 통해 데이터 변환으로 인한 정보 손실을 방지하고, 모델이 수치 데이터의 복잡한 관계를 직접 학습할 수 있도록 설계했습니다.

BERT 기반 모델과 기존 모델의 성능 비교

기존 RIAS 시스템(XGBoost, FT-Transformer, MLP) 모델과 더불어, 새로 설계한 BERT 기반 모델의 AUROC, sensitivity, F1 score를 비교하였습니다.

2. 프로젝트의 Challenges 및 해결한 기법에 대한 자세한 설명 (Challenges in the project and detailed explanation about methods to solve them)

challenges:

1. BERT Tokenizer의 한계

- BERT는 원래 자연어 처리에 사용되는 모델로, 숫자로 이루어진 float 형 데이터 (예: 3.0)를 적절히 임베딩하지 못하는 문제가 있었습니다.
- 예를 들어, 아래와 같이 3.0과 같은 값이 3, .(점), 0으로 개별 토큰으로 나뉘어 데이터의 의미가 왜곡되었습니다.

예시 (Tokenizer 전후 변환 과정):

- **Original:** 3.0
- **Tokenized:** '3', '.', '0'
- 이러한 토큰화는 수치 데이터 간의 연속성을 손실시켜, 모델이 데이터의 관계를 정확히 학습하지 못하도록 방해했습니다.

2. Tabular 데이터의 변환 문제

- 기존 접근법에서는 Tabular 데이터를 자연어 문장으로 변환한 뒤 BERT에 입력하려고 했으나, 변환 과정에서 중요한 정보가 손실되거나 학습 성능 저하가 발생했습니다.
- 예를 들어, 데이터 내의 label 값들이 자연어 변환 과정에서 의미가 제대로 전달되지 않았고, 잘못된 토큰화가 이루어졌습니다.

Original Data	Tokenized Data
Killip Class	'Killip', 'class'
Flow of target vessel	'Flow', 'of', 'target', 'vessel'

이러한 변환은 데이터의 구조적 정보를 왜곡시켜, 모델 성능 저하의 원인이 되었습니다.

해결한 기법 및 방법론:

1. 자연어 변환 과정 생략 및 원본 수치 데이터 입력


- Tabular 데이터를 자연어 문장으로 변환하는 과정을 **완전히 생략**하고, CSV 파일의 수치 데이터를 그대로 모델에 입력하는 방식을 채택하였습니다.
- 수치 데이터를 원본 형태로 처리함으로써 변환 과정에서 발생할 수 있는 정보 손실과 데이터 왜곡을 방지했습니다.

2. 컬럼별 임베딩 레이어 설계

- 각 데이터 컬럼마다 별도의 **Linear Layer**를 사용해 **수치 데이터를 고유 임베딩 벡터**로 변환했습니다.
- 이 방식은 각 컬럼의 고유한 의미를 유지하면서도, 수치 간의 연속적 관계를 정확히 학습할 수 있도록 도왔습니다.

3. Transformer 기반 학습 구조

- 생성된 임베딩 벡터를 BERT 기반의 Transformer 블록에 입력하여 **수치 데이터 간의 상호작용과 패턴**을 학습하도록 설계했습니다.
- 이를 통해 Tabular 데이터의 복잡한 구조적 관계를 효과적으로 반영할 수 있었습니다.




3. 실험 결과 및 분석 (Experimental result & analysis)

1. Training 및 Validation Loss



In-hospital mortality



6M mortality



12M mortality

2. BERT 모델과 RIAS 시스템 성능 비교



Table 2. Performance comparison.

	In-hospital mortality			6-month mortality			12-month mortality		
	AUROC	Sensitivity	F1	AUROC	Sensitivity	F1	AUROC	Sensitivity	F1
XGBoost	0.990 $\pm$ 0.01	0.824 $\pm$ 0.02	0.833 $\pm$ 0.02	0.939 $\pm$ 0.01	0.652 $\pm$ 0.05	0.693 $\pm$ 0.04	0.925 $\pm$ 0.01	0.551 $\pm$ 0.03	0.632 $\pm$ 0.02
FT-Transformer	0.986 $\pm$ 0.01	0.922 $\pm$ 0.02	0.823 $\pm$ 0.03	0.899 $\pm$ 0.01	0.672 $\pm$ 0.03	0.636 $\pm$ 0.03	0.905 $\pm$ 0.01	0.630 $\pm$ 0.52	0.574 $\pm$ 0.03
MLP	0.982 $\pm$ 0.01	0.820 $\pm$ 0.04	0.785 $\pm$ 0.03	0.900 $\pm$ 0.02	0.552 $\pm$ 0.05	0.643 $\pm$ 0.03	0.812 $\pm$ 0.12	0.504 $\pm$ 0.01	0.582 $\pm$ 0.01

The top results are highlighted in bold.

RIAS 시스템 성능

Metric	In-hospital mortality	6-month mortality	12-month mortality	
Loss		0.0299	0.0846	0.1412
Accuracy		0.9891	0.9726	0.9607
Precision		0.8148	0.807	0.7931
Recall		0.8627	0.6133	0.5111
F1-score		0.8383	0.697	0.6216



BERT 모델 성능

In-Hospital Mortality

BERT 모델은 AUC 0.9946과 F1-Score 0.8383으로, RIAS 시스템(XGBoost, FT-Transformer, MLP)의 모든 모델을 상회하며 **가장 우수한 성능**을 기록했습니다.

이는 단기적인 사망률 예측에서 BERT 모델이 Precision(0.8148)과 Recall(0.8627)의 균형을 잘 유지하여 **의미 있는 사망률 예측**을 제공했음을 보여줍니다.

6-Month Mortality

AUC는 BERT 모델(0.9406)과 XGBoost(0.939)가 **유사한 성능**을 보였습니다.

그러나, **Precision(0.807)** 및 F1-Score(0.697)에서 BERT 모델이 RIAS 시스템의 XGBoost(Precision 0.652, F1-Score 0.693)를 상회하며 더 우수한 결과를 기록했습니다.

이는 중기 예측에서도 BERT 기반 모델이 **사망률 예측의 정확성**을 향상시키는 데 강점을 가지고 있음을 시사합니다.

12-Month Mortality

RIAS의 XGBoost 모델은 AUC 0.925 및 Recall 0.551로, BERT 모델(AUC 0.8805, Recall 0.5111)을 상회하는 성능을 보였습니다.

BERT 모델은 12-Month Mortality에서 상대적으로 낮은 Recall(0.5111)과 F1-Score(0.6216)를 보

였으며, **장기 예측 성능 개선**이 필요한 영역으로 확인되었습니다.

이는 장기 예측에서는 수치형 데이터의 **구조적 특성을 추가적으로 반영**하거나, 시간 의존적인 패턴을 학습할 수 있는 **RNN 기반 구조와의 융합** 등 모델 개선의 필요성을 나타냅니다.

BERT 모델의 강점

1. 단기 및 중기 예측에서 우수한 성능
 - 특히 In-Hospital Mortality와 6-Month Mortality에서 높은 AUC와 F1-Score를 기록하며, RIAS 시스템의 기존 모델(XGBoost, FT-Transformer, MLP)을 능가했습니다.
 - 이는 BERT 기반 Transformer 구조가 데이터 간의 복잡한 상호작용을 효과적으로 학습하고, Precision과 Recall의 균형을 잘 유지했기 때문입니다.
2. 단기 예측에서의 높은 신뢰성
 - BERT 모델은 단기 사망률 예측에서 중요한 Recall(0.8627)과 F1-Score(0.8383)를 기록하며, 의미 있는 사망률 예측과 환자 관리에 신뢰할 수 있는 성능을 제공했습니다.

개선이 필요한 부분

- **12-Month Mortality:**
 - XGBoost가 AUC, Recall, F1-Score에서 Custom BERT 모델보다 더 높은 성과를 보임에 따라, 장기 예측에서의 성능 개선이 필요합니다.
 - 이를 위해 장기적인 패턴 학습을 강화하기 위해 **시간 의존적인 특성을 반영하는 RNN 구조**(예: LSTM, GRU)와의 융합 및 **데이터 증강**과 같은 추가적인 접근법이 필요할 것으로 보입니다.

Reference

Kim M, Kang D, Kim MS, et al. Acute myocardial infarction prognosis prediction with reliable and interpretable artificial intelligence system.

Devlin, Jacob, et al. "BERT: Pre-training of deep bidirectional transformers for language understanding."